Glyph2Hand

纯噪声 flow：独立内容编码与多参考风格条件

2026 年 10 月 10 日　当前架构与训练实现，检查点版本 5

1 任务与当前实现

输入为同一作者的 N 个参考手写字 $\{H_i\}_{i=1}^{N}$ 和目标标准字 $K_\star$。参考字不再配同字标准字。模型从标准高斯噪声生成目标字的手写图，目标标准字通过独立内容 token 提供条件。目标手写真值 $H_\star$ 仅用于训练状态和速度监督，不放入参考集合。实际标准字体由数据准备参数 `--font` 指定，训练说明使用文津宋体；代码不硬编码字体。

风格分支将每个参考字独立浓缩为 Z 个描述，然后直接拼接。内容分支采用相同的 patch/SA 结构，参数与 SA 深度独立，不做最后的 CA 浓缩。主干堆叠 **SA** $\rightarrow$ **Content CA** $\rightarrow$ **Style CA** $\rightarrow$ **FFN**。训练和验证只使用 flow MSE，每个 batch 更新一次；验证、预览使用当前模型。完整配置、运行命令、日志与 I/O 处理见上一级 `README.md` 和 `TRAINING.md`。`README.v1-with-diagrams.*` 为历史设计；本文描述代码行为，不提供生成质量结论。

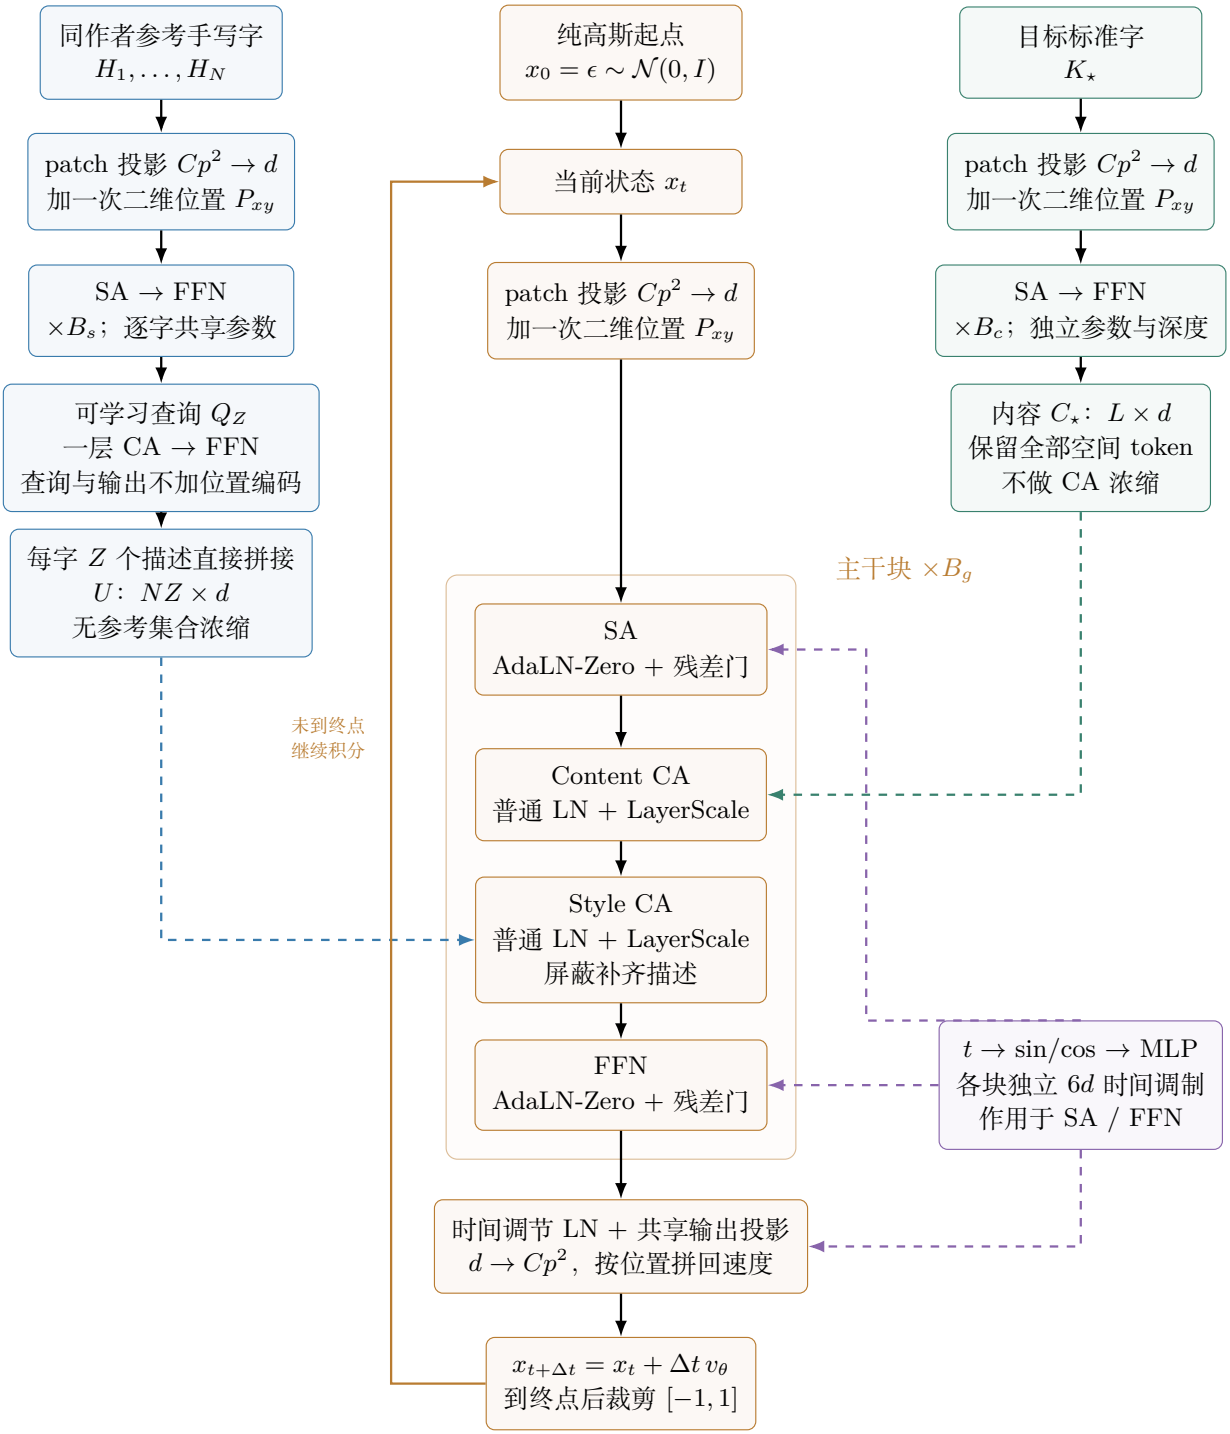
1.1 张量与符号

采用通道在前布局。批量为 B，通道 $C = 1$，图像边长 n，patch 边长 p，空间 token 数 $L = (n/p)^2$，特征维 d，每字描述数 $Z =$ `description_tokens`。

张量	形状	用途
参考手写字	$[B, N, C, n, n]$	同一 episode 来自同一作者
目标标准字	$[B, C, n, n]$	内容条件，独立编码
参考有效掩码	$[B, N]$	True 表示有效，每个样本至少一个
内容 $C_\star$	$[B, L, d]$	保留空间位置的内容序列
风格 U	$[B, NZ, d]$	各参考描述直接拼接
当前状态 / 速度	$[B, C, n, n]$	像素空间 flow
时间	$[B]$	连续流位置，训练均匀采样

字图映射为 $[-1, 1]$，白色 $+1$、黑色 -1；噪声、中间状态和速度不受该范围约束。底层模型可配置通道数，现有数据处理、训练器和预览仅支持单通道。

架构图：三条 patch 分支与两类条件读取



条件编码在积分前各计算一次；每层分别读取同一份 $C_\star$ 与 U

风格、内容和状态均在 patch 投影后加一次位置编码；风格浓缩查询及描述不加位置编码。图中的 CA 表示主干独立注意力子层；风格浓缩模块含一层 CA 和一个 FFN，均有前置 LN 与 LayerScale 残差。LayerScale 是不依赖时间的可学习逐通道残差系数，初值为 10^{-4}。

2 风格与内容编码

对第 i 个参考手写字，定义

$$R_i = E_s\big(\mathrm{Patch}_s(H_i) + P_{xy}\big) \in \mathbb{R}^{L\times d}, \qquad U_i = \mathrm{Pool}(Q_Z, R_i) \in \mathbb{R}^{Z\times d}.$$

每字独立编码，各字共享 patch 投影、$B_s =$ `local_depth` 个 SA–FFN 块和可学习查询 Q_Z。每个 SA–FFN 子层采用普通前置 LN 与 LayerScale 残差，FFN 为两层线性映射，中间 GELU。**Pool 中恰好只有一层 CA**，随后一个 FFN：

$$\begin{aligned}\widetilde{Q} &= Q_Z + \gamma_{\mathrm{ca}} \odot \mathrm{MHA}(\mathrm{LN}_q(Q_Z), \mathrm{LN}_r(R_i), \mathrm{LN}_r(R_i)),\\ U_i &= \widetilde{Q} + \gamma_{\mathrm{ffn}} \odot \mathrm{FFN}(\mathrm{LN}_f(\widetilde{Q})).\end{aligned}$$

γ_{ca} 和 γ_{ffn} 是初值为 10^{-4} 的可学习逐通道 LayerScale。Q_Z 是共享训练参数，以标准差 0.02 的正态分布初始化；查询和浓缩输出均不添加位置编码。浓缩后不再做自注意力，不保留原始空间 token 旁路。直接拼接 $U = [U_1; \ldots; U_N]$，主干读取全部 NZ 个描述，没有集合浓缩层或其他汇总查询。描述槽位不等于预先指定的笔画类别，内容与风格的严格解耦也不由结构保证。

内容分支为

$$C_\star = E_c\big(\mathrm{Patch}_c(K_\star) + P_{xy}\big) \in \mathbb{R}^{L\times d}.$$

其 patch 投影和 SA–FFN 与单参考字风格编码同构，参数完全独立，$B_c =$ `content_depth` 可单独调整；不执行最后的 Pool，保持空间 token。内容和风格都不接受时间/当前状态输入，可在积分步之间缓存，训练更新后缓存需重算。

2.1 参考重排与掩码

参考重排只会重排 U 的整组行。主干 Style CA 对 K/V 同步重排不变，因此同样重排有效掩码后，固定内容、状态和时间的速度结果不变，允许浮点误差。代码不对拼接序列再添加组序号或位置编码。参考掩码 True 表示有效，扩展到每字 Z 个描述后，在每层 Style CA 中取反为 padding mask。省略掩码时全部有效，拒绝一个样本所有参考均无效的情况。补齐图像必须使用有限数值；数据集补白 +1，补齐槽仍会参加逐字编码。

3 主干与时间调制

主干仅将当前流状态分块：$T = \mathrm{Patch}_g(x_t) + P_{xy}$。目标标准字只作为内容 memory，不拼为图像通道，也不参与起点构造。每个 block 使用独立时间映射生成 SA/FFN 的缩放、平移和残差门：

$$(a_s, b_s, g_s, a_f, b_f, g_f) = \mathrm{Split}_6(\mathrm{Linear}(\mathrm{SiLU}(e(t)))), \quad D_j(T) = (1 + a_j) \odot \mathrm{LN}_j(T) + b_j.$$

六个 d 维向量在该样本全部 token 间广播，gate 不使用 sigmoid。完整顺序为

$$\begin{aligned}A &= D_s(T),\\ T_s &= T + g_s \odot \mathrm{MHA}_s(A, A, A),\\ T_c &= T_s + \gamma_c \odot \mathrm{MHA}_c(\mathrm{LN}_{cq}(T_s), \mathrm{LN}_{ck}(C_\star), \mathrm{LN}_{ck}(C_\star)),\\ T_u &= T_c + \gamma_s \odot \mathrm{MHA}_u(\mathrm{LN}_{uq}(T_c), \mathrm{LN}_{uk}(U), \mathrm{LN}_{uk}(U)),\\ T^+ &= T_u + g_f \odot \mathrm{FFN}(D_f(T_u)).\end{aligned}$$

Content CA 和 Style CA 参数独立，均为普通前置 LN 和静态 LayerScale 残差，没有单独的时间调节；γ_c, γ_s 初值为 10^{-4}，并在训练中学习。SA 和 FFN 的 LN 无仿射，$\varepsilon = 10^{-6}$；普通 LN 有可学习仿射，$\varepsilon = 10^{-5}$。所有 MHA 为 batch-first、dropout 0、带 bias，Q/K/V 独立投影，不绑定 K/V，调用不返回注意力权重。

时间特征频率为 $f_k = \exp(-\log(10000)k/(F/2))$，原始特征拼接 $\cos(t\tau f_k)$、$\sin(t\tau f_k)$，再经 Linear–SiLU–Linear 得到 $e(t)$。F 为时间特征维，τ 为时间放大倍数。二维位置按行/列各占 $d/2$ 维，每轴拼接 sin/cos。位置和频率为非持久化 buffer，不写入 state dict。

输出头用独立 SiLU–Linear 产生 $2d$ 个 scale/shift，调节无仿射 LN，再共享线性投影为每块 Cp^2 个速度并拼回图像。主干 $6d$ 调制、输出头 $2d$ 调制和速度投影均零初始化；LayerScale 初值为 10^{-4}，初始速度为零，主干块从接近恒等的残差更新开始。

4 flow 损失

4.1 纯噪声 flow MSE

独立采样 $\epsilon \sim \mathcal{N}(0, I)$ 和 $t \sim \mathcal{U}(0, 1)$：

$$x_0 = \epsilon, \qquad x_t = (1-t)\epsilon + tH_\star, \qquad u = H_\star - \epsilon,$$
$$\mathcal{L}_{\text{flow}} = \mathbb{E}\left[\frac{1}{Cn^2}\|v_\theta(x_t, t, C_\star, U) - u\|_F^2\right].$$

训练器用 float32 平均样本、通道和像素的平方误差，不裁剪训练状态。标准字只进入内容编码，参考字只进入风格编码；两者与主干共同反向训练。训练和验证都只统计 flow MSE，训练目标为

$$\mathcal{L}_{\text{train}} = \mathcal{L}_{\text{flow}}.$$

每个 batch 更新一次优化器；日志中的 `train_loss` 和 `val_loss` 都是该 MSE。

5 配置与采样

模型字段	默认值	含义
`image_size / patch_size / in_channels`	64/8/1	$L = 64$，单通道
`hidden_size / num_heads / mlp_ratio`	256/8/2	每头 32，FFN 内宽 512
`local_depth / content_depth`	8/8	风格、内容 SA 深度独立
`generator_depth`	8	双 CA 主干深度
`description_tokens`	16	每字 Z 个描述
`time_frequency_size / time_scale`	256/1000	时间编码维度与倍数

图像边长须整除 patch 边长，d 可被头数和 4 整除，时间特征维为正偶数，三个 SA 深度允许为 0。时间特征维默认在类定义时确定为 256，单独改 d 不会自动同步。默认参数总数 20,901,440：参考 4,769,792，内容 4,237,568，主干 11,894,080，其中包含初值为 10^{-4} 的 LayerScale 参数。

训练字段	默认值	含义
`steps / batch_size`	100000/64	每 batch 一次优化器更新
`min_references / max_references`	4/4	默认 $NZ = 64$；可设数量范围
`learning_rate / min_lr_ratio`	10^{-4}/0.1	基础 LR 与最终比例
`warmup_steps`	1000	线性预热后余弦衰减
`weight_decay / gradient_clip`	0.01/1	AdamW 衰减与全局 L2 阈值
`precision / preload_to_gpu / workers`	BF16 / False / 8	精度与数据存放方式
`val_batches / validate_every`	16/1000	验证批数与间隔
`save_every / log_every`	500/50	保存与日志间隔
`sample_steps / seed`	32/42	预览 Euler 步数与种子

新训练读取 `src/config.py`，AdamW betas 为 $(0.9, 0.95)$，全部参数同组衰减。

CUDA 支持 FP32、BF16、FP16 并启用 TF32；CPU 实际为 FP32，只有 FP16 启用 GradScaler。先反缩放、诊断和裁剪梯度，再更新参数；范数归约非有限时以 float64 重算。真实异常梯度不更新参数：FP16 降低 scale 并复用同一 batch/时间/噪声，最多尝试 16 次；BF16/FP32 或非有限损失直接停止，保留成功保存的检查点。

采样时先计算 $C_\star, U$，从 $x_0 \sim \mathcal{N}(0, I)$ 出发，J 步 Euler：

$$t_j = j/J, \qquad x_{j+1} = x_j + J^{-1} v_\theta(x_j, t_j, C_\star, U), \quad j = 0, \ldots, J-1.$$

只在返回时裁剪 $[-1,1]$，灰度映射由调用方完成。可提供固定 noise 复现实验。没有额外随机积分量；内容和风格每次采样各编码一次，主干每步仍重算各层 memory LN/K/V，没有 K/V cache。