Glyph2Hand

成对参考条件下的单字生成：交叉注意力 DiT 与流匹配

历史版本说明（2026 年 10 月 5 日）：本文件保存首版设计，不代表当前实现。现行架构见同目录的 `README.tex` 与 `README.pdf`：目标标准字只用于构造加噪起点，生成主干已移除目标标准字提示通道，仅输入当前状态、时间及参考风格。下文中的纯噪声起点和双通道目标分支均为历史设计。

0 基本介绍

根据同一书写者的样本字，生成指定汉字的手写图。输入为样本序列 $(H_i)_{i=1}^m$、对应的楷体序列 $(K_i)_{i=1}^m$，以及目标字的楷体图 $K_\star$；H_i 与 K_i 表示同一个汉字，$m \geq 1$。输出 $\widehat{H}_\star$ 应保持目标字内容，并符合样本笔迹风格。所有图像均为 $n \times n$ 单通道灰度图。参考对整体重排不改变输出；每对内部的对应关系必须保留。目前为首版设计，尚未实现和验证效果。

1 模型架构

直接在灰度图空间学习从高斯噪声到手写字的连续变化。DiT 指用于这一生成过程的 Transformer；每层均用交叉注意力读取参考特征。

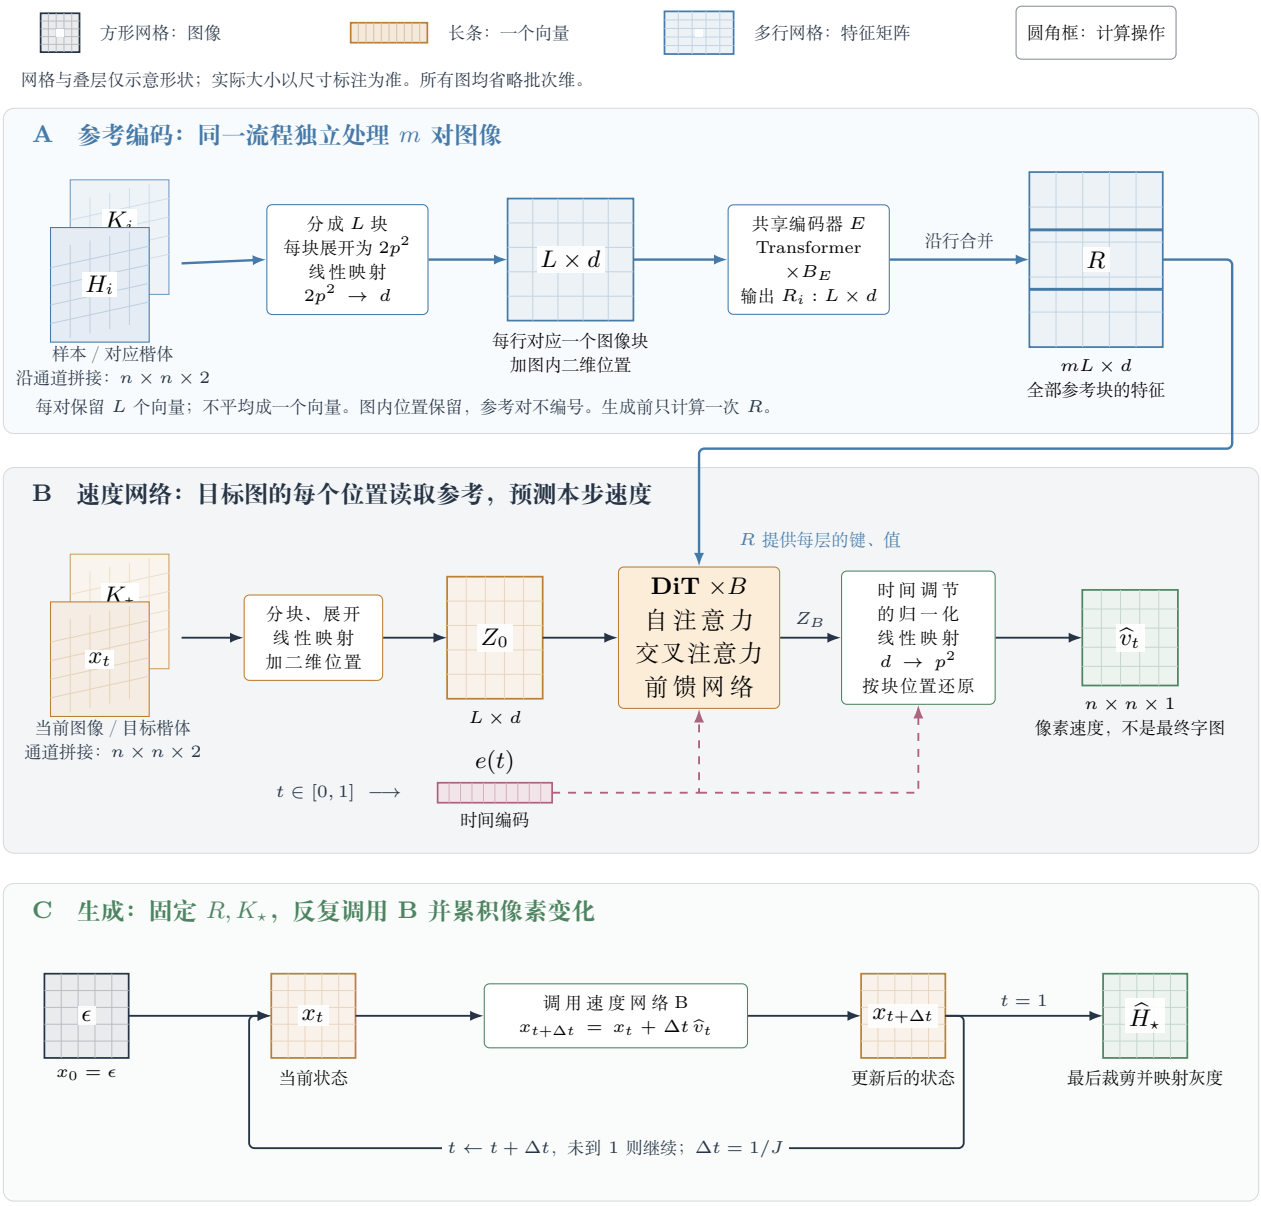


图 1：总体数据流。蓝色为参考，橙色为目标生成特征，粉色虚线为时间条件，绿色为输出。

1.1 图像分块与参考编码

参考分支将 H_i, K_i 沿通道拼接；目标分支将 $x_t, K_\star$ 沿通道拼接，均得到双通道图。将图像划分为不重叠的 $p \times p$ 块，要求 p 整除 n；每张图有 $L = (n/p)^2$ 块。每块线性映射为 d 维向量，并加入固定二维正弦余弦位置编码。参考编码器由 B_E 层 Transformer 组成，每层依次采用层归一化、自注意力及残差相加，再采用层归一化、两层前馈网络及残差相加。前馈网络使用 GELU 激活。每对参考独立编码，输出 R_i；沿块列表合并得到 R，不做全局平均。时间 t 采用正弦余弦编码后经两层前馈网络（SiLU 激活）得到时间特征，再送入各 DiT 层和输出头。首版不使用随机丢弃特征的 dropout；生成时除初始噪声外不引入额外随机量。

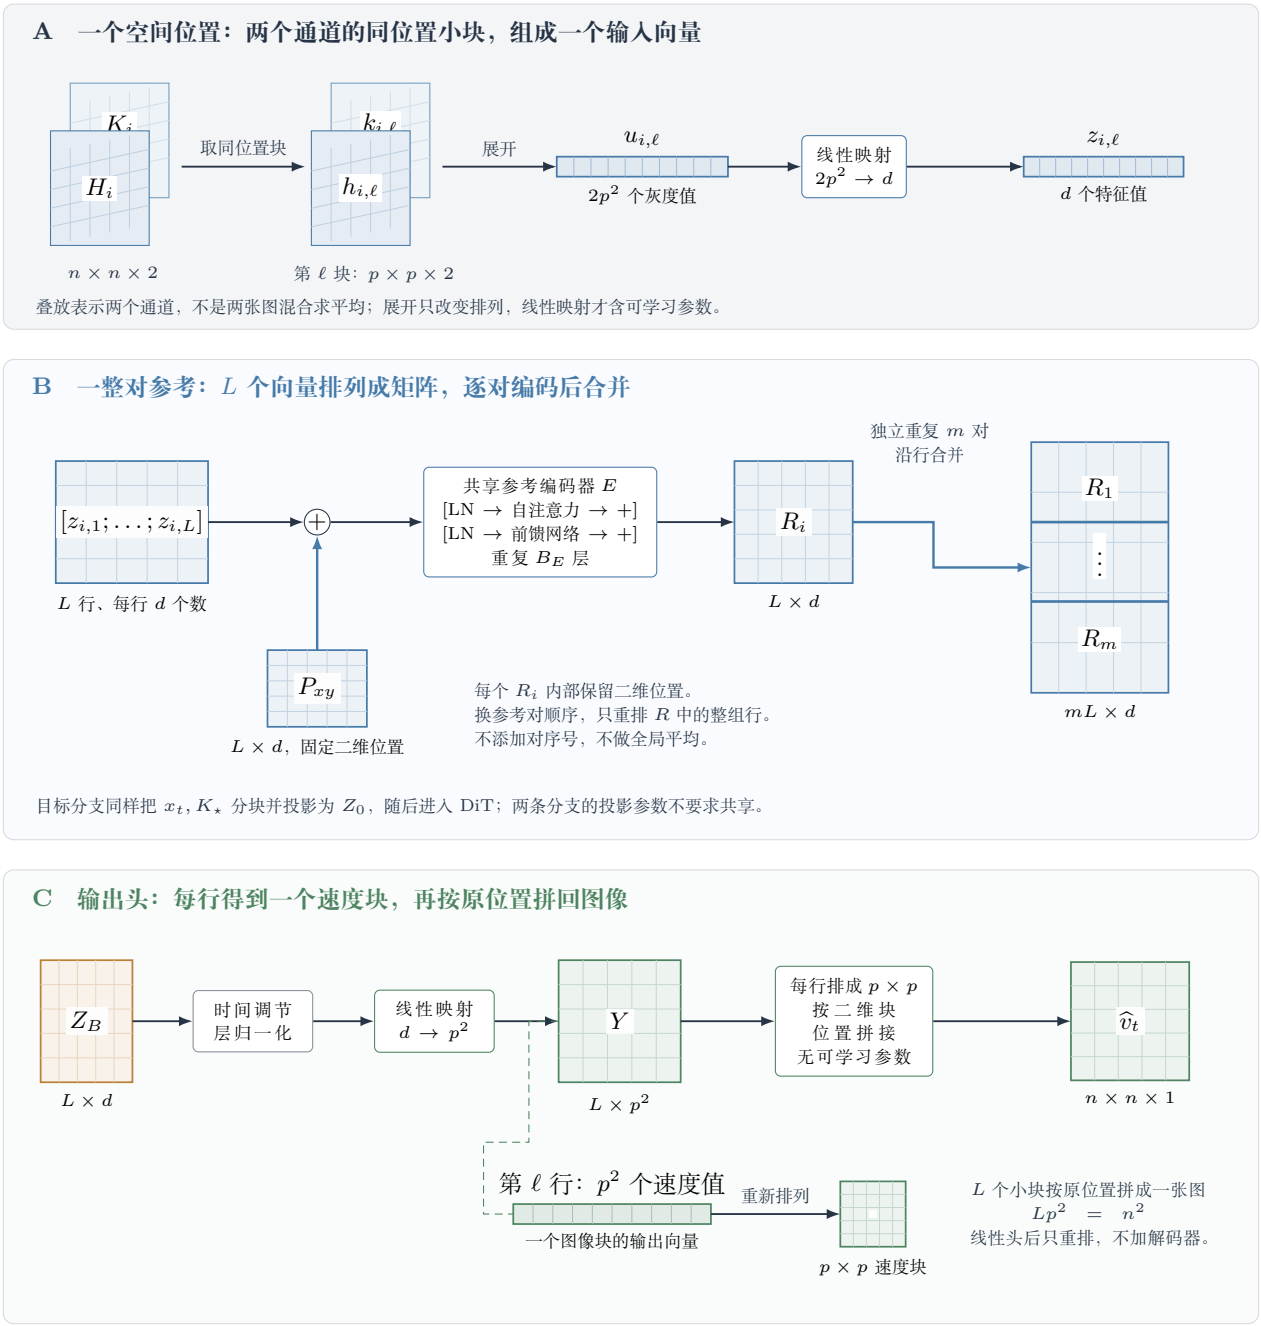


图 2：输入与输出形状详解。特征矩阵每行代表一个空间块；斜叠的图像平面表示通道。

1.2 DiT 层与交叉注意力

每个 DiT 层按图 3 顺序计算。自注意力连接目标图内的所有块；交叉注意力让每个目标块读取所有参考块；前馈网络逐块更新特征。

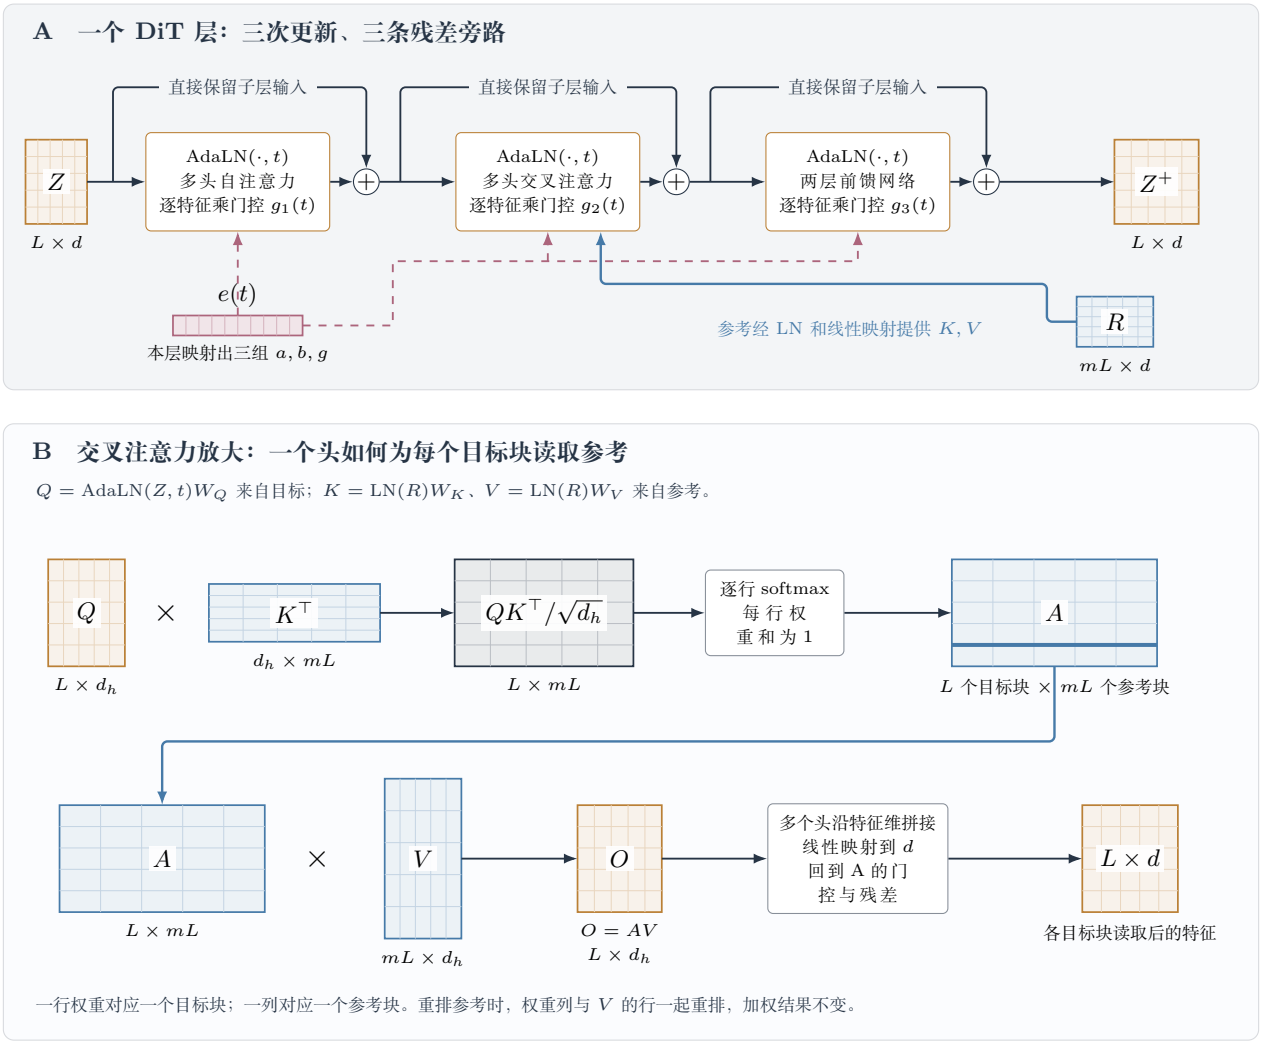


图 3：DiT 内部与交叉注意力。+ 为残差相加；× 为矩阵乘法；门控为逐特征相乘。

时间条件采用 AdaLN-Zero：对每个子层输入 Z，计算 $\mathrm{AdaLN}(Z,t) = (1+a(t)) \odot \mathrm{LN}(Z) + b(t)$，再将子层结果乘以门控向量 $g(t)$ 后加回 Z。$a, b, g \in \mathbb{R}^d$ 在目标块之间共享，三个子层各用一组；产生这些向量的最后一个线性层零初始化。输出头采用时间调节的层归一化和 $d \to p^2$ 线性映射，再按块位置还原速度图。

交叉注意力的单头计算为

$$Q = \mathrm{AdaLN}(Z,t)W_Q, \quad K = \mathrm{LN}(R)W_K, \quad V = \mathrm{LN}(R)W_V, \qquad O = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_h}}\right)V.$$

其中 Z 是该交叉注意力子层的输入，d_h 是每个注意力头的维数。多个头的结果拼接后经线性映射，再做门控及残差相加。Q 来自目标生成分支；K, V 来自参考分支。层归一化均只沿每个块的特征维进行。

1.3 参考对顺序无关

每对独立编码；图内位置随该对特征一起移动。参考特征合并后，不再加入序列位置编码，也不使用按参考顺序限制读取的遮罩。设 P 表示参考对重排对应的行置换，则 $K' = PK$、$V' = PV$，且

$$\mathrm{softmax}\left(\frac{Q(PK)^\top}{\sqrt{d_h}}\right) PV = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_h}}\right) V.$$

因此参考对重排不改变预测速度；固定初始噪声和积分步骤后，最终输出也不变（允许浮点计算误差）。这不允许单独打乱样本序列或楷体序列。若用补齐条目组成批次，交叉注意力必须屏蔽这些条目。

1.4 流匹配：训练与生成

灰度值统一映射到 $[-1, 1]$。训练时，$H_\star$ 是同一书写者的目标手写真值，仅用于构造训练状态和监督目标；它不是参考输入。取 $t \sim \mathcal{U}(0,1)$，独立噪声 $\epsilon \sim \mathcal{N}(0, I)$，定义

$$x_t = (1-t)\epsilon + tH_\star, \qquad u = H_\star - \epsilon, \qquad \mathcal{L} = \mathbb{E}\left[\frac{1}{n^2}\left\|v_\theta(x_t, t, K_\star, R) - u\right\|_F^2\right].$$

网络预测从噪声走向真值的速度 u。参考编码器与 DiT 联合训练；生成时固定 $R, K_\star$，从 $x_0 = \epsilon$ 出发，求解

$$\frac{dx_t}{dt} = v_\theta(x_t, t, K_\star, R), \qquad t : 0 \longrightarrow 1.$$

首版采用图 1 的等步长 Euler 更新，$\Delta t = 1/J$，共 J 步；只在最后裁剪到 $[-1, 1]$，再映射回灰度范围。图像边长 n、块边长 p、特征维数 d、层数 B_E, B、注意力头数、前馈网络宽度及步数 J 尚待实验确定。

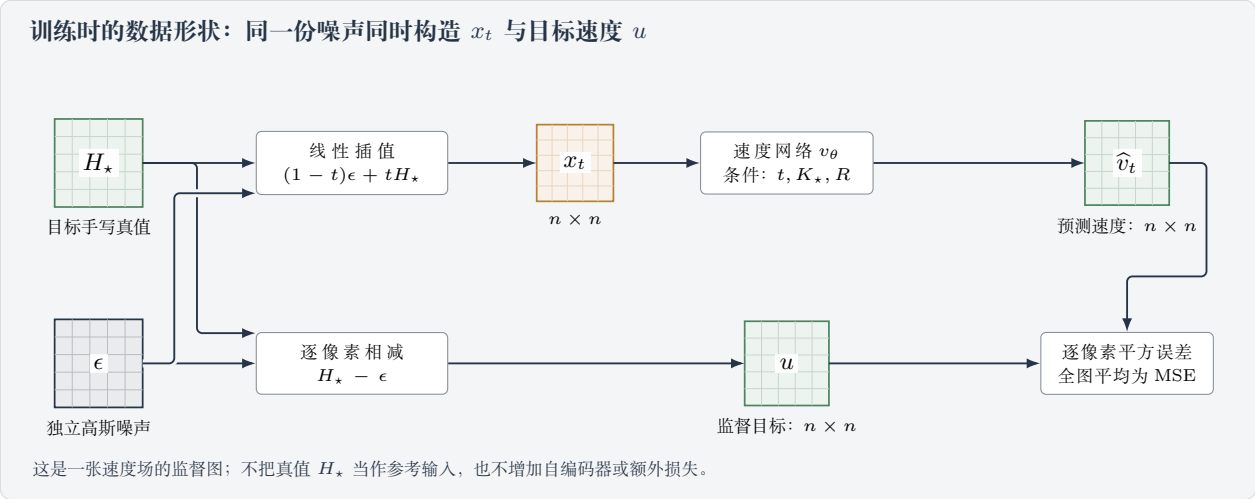


图 4：流匹配训练数据流。与图 1C 的生成流程区分；训练目标和网络结构均未改变。

2 未来可能方向

初版灰度模型效果满足要求后，再考虑将全部输入和输出扩展为 $n \times n$ 的三通道 RGB 图像。粗细、直曲及火焰字体等风格变化另作后续实验；改为 RGB 本身不保证这些能力，其中粗细、直曲也可在灰度图中研究。