Glyph2Hand

分层参考编码与条件流匹配：架构图与设计说明

2026 年 10 月 4 日　三阶段参考编码与标准字起点 flow

1　任务、范围与核心假设

根据同一书写者的若干参考字，生成指定汉字的手写图。输入为

$$\mathcal{C} = \{(H_i, K_i)\}_{i=1}^{N}, \qquad K_\star,$$

其中 H_i 是参考手写图，K_i 是同一个汉字的标准字体图；$K_\star$ 是目标汉字的标准字体图。本版 $K_i, K_\star$ 统一使用微软雅黑（Microsoft YaHei）；符号 K 仅作为标准字图的记号。图中的手写侧用楷书字形作示意，不代表训练样本。一组指一个对应的 (H_i, K_i)，不是一张独立图像。所有参考手写图来自同一书写者，$N \geq 1$。输出 $\widehat{H}_\star$ 应同时保持目标字内容和参考笔迹风格。训练真值 $H_\star$ 不进入参考集合，也不作为生成网络的独立条件输入。

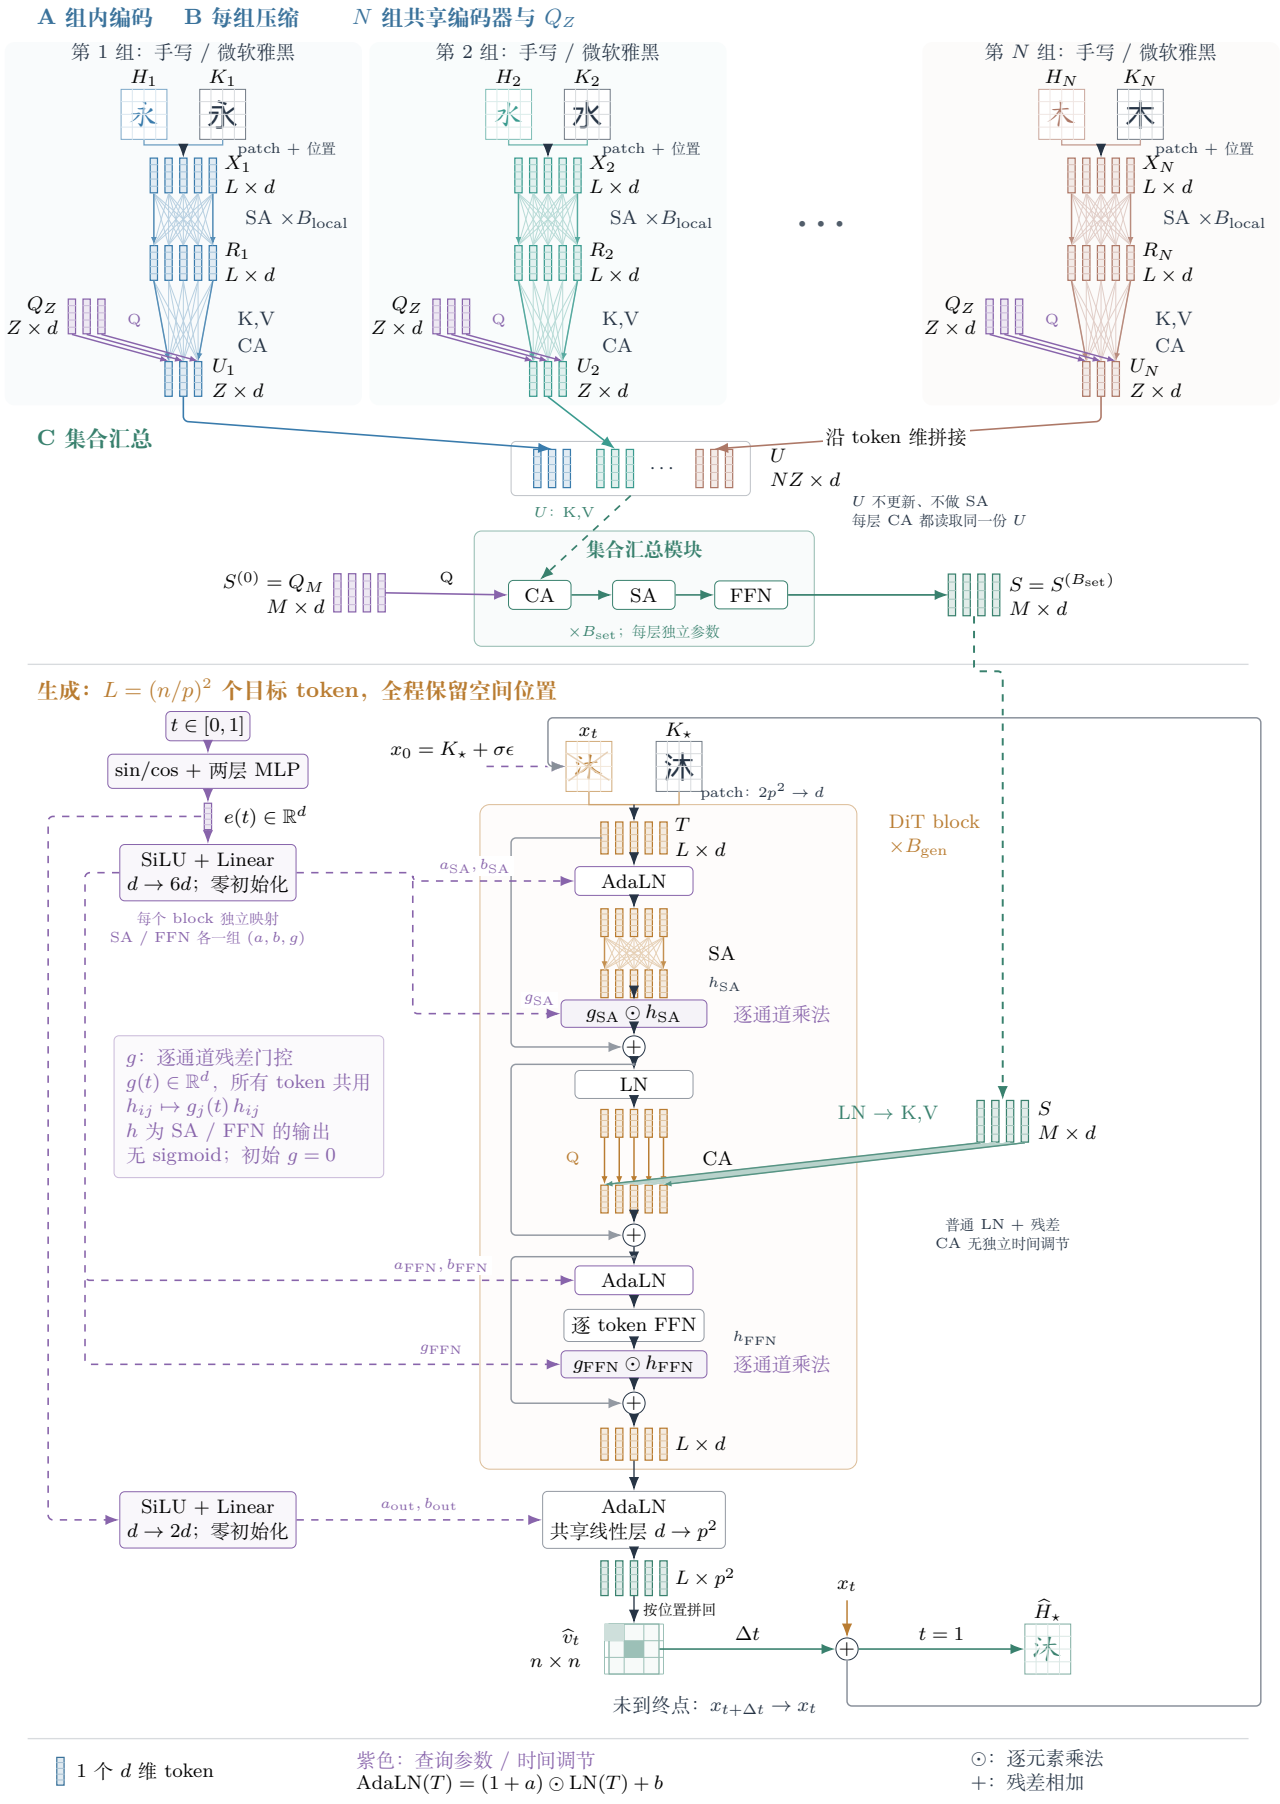
本版参考分支采用以下顺序：

1. 每组独立编码，在整字上下文中理解局部形状以及手写与标准字之间的关系。
2. 每组压缩为 Z 个语义描述 token，表示从该参考字中观察到的写法证据。
3. 由 M 个可学习查询初始化风格 token，经过 B_{set} 个集合汇总块；每层依次用交叉注意力读取全部 NZ 个描述、在 M 个风格 token 间做自注意力，再经过前馈网络。

核心假设：组内结构已被编码进 Z 个描述，后续融合可以主要依据描述内容，不再显式依赖原始 patch 的分组关系。这不意味着字符内容被完全消除，也不保证每个 token 对应一种笔画。笔画、部件及其位置仍可能是解释某种写法所必需的信息。这一假设和压缩容量需要通过实验验证；当前文档与 `src` 中的模型骨架保持一致，尚无训练或效果结论。

生成分支暂按“目标标准字加噪声作为起点”的像素空间 flow 写出完整公式。噪声强度、各层数和 token 数量均为可调实验超参数，尚未由实验确定。

架构总览　参考集合压缩与条件 flow



条带数量为示意；实际数量以 L, Z, M, NZ 为准。连线表示注意力读取关系；QKV 在 MHA 内独立投影。标准字使用微软雅黑，手写侧字形仅作示意。生成主干的 SA、FFN 采用 AdaLN-Zero，生成 CA 采用普通 LN 与残差；集合汇总的 CA、SA、FFN 均采用普通前置 LN 与残差。参考逐组编码的归一化、残差及 FFN 从略；最终字图经过灰度映射。

2 统一符号与数据形状

所有图像先映射至 $[-1,1]$，采用 $n\times n$ 单通道灰度图。块边长为 p，要求 $p\mid n$。每边块数为 $q=n/p$，每组块数为 $L=q^2$。这里使用 q 表示每边块数，避免与 flow 状态 x_t 混淆。下表省略批次维；每行特征都是一个 d 维 token。

符号	形状 / 含义	职责
N	参考对数量	随输入变化，至少为 1
Z	每组描述数量	单字证据容量，固定超参数
M	最终风格数量	整个参考集合的输出容量，固定超参数
B_{set}	集合汇总层数	每层依次执行 CA、SA、FFN；代码默认 2，至少为 1
X_i	$L\times d$	第 i 组的初始 patch 特征
R_i	$L\times d$	经过组内注意力的空间特征
Q_Z	$Z\times d$	所有组共用的可学习压缩查询
U_i	$Z\times d$	第 i 组的语义描述
U	$NZ\times d$	全部组描述沿行拼接，直接提供键和值
Q_M	$M\times d$	可学习的集合汇总查询
S	$M\times d$	最终风格条件
$T^{(b)}$	$L\times d$	生成主干第 b 层的目标特征
$x_t,\widehat{v}_t$	$n\times n\times 1$	当前生成状态、预测像素速度

Z 和 M 都表示 token 数量，不表示特征维度；它们不必相等，也没有预设大小关系。Q_Z,Q_M 是训练得到的模型参数，不是每次生成时重新采样的随机量。

3 参考分支：从成对字图到固定风格表示

3.1 注意力块的具体约定

为使下文公式没有歧义，本文采用带残差、前置层归一化和前馈网络的注意力块。交叉注意力块 $\mathrm{CA}(A,B)$ 由 A 提供查询，B 提供键和值：

$$\begin{aligned}\widetilde{A}&=A+\mathrm{MHA}(\mathrm{LN}_A(A),\mathrm{LN}_B(B),\mathrm{LN}_B(B)),\\ \mathrm{CA}(A,B)&=\widetilde{A}+\mathrm{FFN}(\mathrm{LN}_F(\widetilde{A})).\end{aligned}$$

自注意力块 $\mathrm{SA}(A)$ 为

$$\begin{aligned}\widetilde{A}&=A+\mathrm{MHA}(\mathrm{LN}_A(A),\mathrm{LN}_A(A),\mathrm{LN}_A(A)),\\ \mathrm{SA}(A)&=\widetilde{A}+\mathrm{FFN}(\mathrm{LN}_F(\widetilde{A})).\end{aligned}$$

这里的 LN 是逐 token 的层归一化，不是 QKV 投影。$\mathrm{MHA}(X_Q,X_K,X_V)$ 的三个参数表示投影前的特征来源，模块内部再进行各头的 QKV 线性投影。以第 h 个头为例，省略可选偏置：

$$\begin{aligned}Q_h&=X_QW_Q^{(h)},\qquad K_h=X_KW_K^{(h)},\qquad V_h=X_VW_V^{(h)},\\ O_h&=\mathrm{softmax}\!\left(\frac{Q_hK_h^{\top}}{\sqrt{d_h}}\right)V_h,\\ \mathrm{MHA}(X_Q,X_K,X_V)&=\mathrm{Concat}_h(O_h)W_O.\end{aligned}$$

d_h 是每头维度，W_O 是多头结果拼接后的输出投影。本稿的 $W_Q^{(h)},W_K^{(h)},W_V^{(h)}$ 分别参数化，不共享权重。因此自注意力中三个输入均为 $\mathrm{LN}_A(A)$，仅表示 Q、K、V 来自同一份特征，不施加投影后的 $Q_h=K_h=V_h$ 约束。同理，交叉注意力中键和值均来自 $\mathrm{LN}_B(B)$，也不表示 $K_h=V_h$。

与共享键值的区别：在本稿所用的相同键值维度下，若将 K、V 投影及其偏置（如有）绑定，或直接令 $V_h=K_h$，才是显式约束投影后 $K=V$ 的另一种结构；本稿不采用该约束。上述 QKV 投影约定也适用于生成主干中的多头注意力。前馈网络暂用两层线性映射和 GELU；归一化仅沿特征维，不跨 token 或参考组。不同阶段、不同层拥有各自参数；只有明确说明的逐组操作共享参数。

下文“注意力池化”采用 Set Transformer 的 PMA 思想：固定数量的可学习查询读取可变数量的输入。这里给出了本稿使用的具体块结构，不宣称逐项复现原论文的归一化和前馈配置。

3.2 阶段 A：组内分块与上下文编码

将一组 H_i, K_i 沿通道拼接为 $n \times n \times 2$。同位置的两个 $p \times p$ 小块一起展开，得到 $2p^2$ 维向量，再投影到 d 维。这不是把手写和标准字混合平均，也不是分别产生两套无配对关系的 token。定义

$$X_i = \mathrm{PatchEmbed}_{\mathrm{ref}}([H_i, K_i]) + P_{xy} \in \mathbb{R}^{L \times d}, \qquad R_i = E_{\mathrm{local}}(X_i).$$

$P_{xy} \in \mathbb{R}^{L \times d}$ 为图内二维位置编码；暂用固定二维正弦余弦编码。E_{local} 由 B_{local} 层 SA 组成。每组的 L 个 token 可以互相读取，但此阶段不读取其他参考组。所有组使用相同的分块投影、位置编码和编码器参数。

这一阶段保留 L 个空间位置。目的在于先获得带整字上下文的局部描述，为跨字比较提供依据；仅添加二维位置、然后直接把原始 patch 混合，不能完整表达哪些 patch 属于同一个字。组内编码也不保证自动学到可解释的笔画分类。

3.3 阶段 B：每组压缩为 Z 个语义描述

用同一套可学习查询 $Q_Z \in \mathbb{R}^{Z \times d}$ 独立读取各组：

$$U_i = \mathrm{CA}_{\mathrm{local\ pool}}(Q_Z, R_i) \in \mathbb{R}^{Z \times d}.$$

查询来自 Q_Z，键和值来自第 i 组的 R_i。每个查询均可读取该组的全部 L 个空间特征；输出位置对应查询槽位，不再对应固定图像块。各组之间共享 Q_Z 和此注意力块的全部参数。

本稿采用一次上述压缩，随后拼接各组描述，供 M 个风格 token 在多层集合汇总中反复读取。压缩后的 U_i 不再进行组内或跨组自注意力。压缩后不再保留 R_i 到主干或最终池化的旁路，因而 Z 是真实的信息瓶颈。

相同查询槽位为跨字描述提供共同的学习起点，但不强制语义完全对齐。例如不能预先断言“第一个 token 永远表示横画”。这里的 U_i 是来自单字的证据：有些写法在该字中没有出现，模型需要在后续集合融合中结合其他字。压缩不会自动实现内容与风格的严格解耦，也不要求每个描述能独立解释。

3.4 阶段 C：多层 CA–SA–FFN 汇总为 M 个风格 token

将各组描述沿 token 维拼接，作为每个集合汇总层的固定键值来源：

$$U = [U_1; \ldots; U_N] \in \mathbb{R}^{NZ \times d}, \qquad S^{(0)} = Q_M \in \mathbb{R}^{M \times d}.$$

设集合汇总深度为 $B_{\mathrm{set}} \geq 1$，当前代码默认 $B_{\mathrm{set}} = 2$。第 b 层先由当前风格 token 读取 U，再在 M 个风格 token 之间进行自注意力，最后执行逐 token 前馈网络：

$$\begin{aligned}
C^{(b)} &= S^{(b)} + \mathrm{MHA}^{(b)}_{\mathrm{ca}}\left(\mathrm{LN}^{(b)}_{q}(S^{(b)}), \mathrm{LN}^{(b)}_{u}(U), \mathrm{LN}^{(b)}_{u}(U)\right), \\
A^{(b)} &= C^{(b)} + \mathrm{MHA}^{(b)}_{\mathrm{sa}}\left(\mathrm{LN}^{(b)}_{s}(C^{(b)}), \mathrm{LN}^{(b)}_{s}(C^{(b)}), \mathrm{LN}^{(b)}_{s}(C^{(b)})\right), \\
S^{(b+1)} &= A^{(b)} + \mathrm{FFN}^{(b)}\left(\mathrm{LN}^{(b)}_{f}(A^{(b)})\right), \qquad b = 0, \ldots, B_{\mathrm{set}} - 1, \\
S &= S^{(B_{\mathrm{set}})}.
\end{aligned}$$

每层拥有独立的 CA、SA、FFN 和归一化参数。CA 的单头注意力矩阵形状为 $M \times NZ$，SA 的注意力矩阵形状为 $M \times M$。第一层查询由可学习参数 Q_M 初始化；后续层查询是上一层已经融合参考信息的风格 token。

拼接只是键值输入的整理，不含可学习参数，也不构成独立编码阶段。U **不进行自注意力，也不在集合汇总中被更新；每层 CA 都读取同一份** U。这里的“不更新 U”指前向计算中的信息流；训练梯度仍可通过每层键值分支回传至逐组编码器。补齐参考产生的描述在每一层 CA 中使用相同的键值掩码。Q_M 与 Q_Z 是不同的参数集合，即使 $M = Z$ 也不共享。

汇总时不添加参考组序号、拼接后的绝对序列位置或新的空间网格位置。组内空间与上下文信息可以存在于描述内容中，但查询不再显式访问原始分组关系。这沿用阶段 B 的假设：压缩描述应足以支持内容驱动的集合汇总。

S 表示对整个参考集合的风格总结；其行数与 N 无关，但数值内容依赖全部有效参考。M 是表示容量，不等于预先定义的中文风格属性数量。参考分支只依赖 $\mathcal{C}$，不依赖目标字 $K_\star$、时间 t 或当前状态 x_t。因此同一组参考的 S 可以在多个目标字和各 flow 步之间复用。训练时不截断其梯度，参考分支与生成主干联合优化；训练更新后缓存需重新计算。

4 参考顺序无关性与可变数量输入

本任务要求参考对整体重排不改变输出；不允许仅重排 H_i 或仅重排 K_i。逐组编码与压缩使用共享参数，因此组重排只会重排 U 的整组行，得到 $U' = PU$。由于键值投影与归一化均逐 token 进行，对应有 $K' = PK$、$V' = PV$。任意固定查询对键和值的同步重排不变。以单头为例，

$$\mathrm{softmax}\left(\frac{Q(PK)^\top}{\sqrt{d_h}}\right)PV = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_h}}\right)V.$$

第一层 CA 因而对参考重排不变；其后的 M token 自注意力、逐 token 前馈网络和残差也不引入参考顺序。以此逐层归纳，后续 CA 的查询同样不随参考重排变化，所以最终 S 不变。固定初始噪声和积分设置后，生成结果也不变，允许浮点计算误差。本稿暂不使用 dropout；若以后引入随机操作，需区分确定性推理与随机训练中的性质。

批处理中不同样本可以有不同 N。补齐参考组产生的全部 Z 个描述必须在最终交叉注意力中作为无效键值屏蔽。M 个查询均有效，但不得读取这些补齐 token。应避免给一个查询构造全部键均不可见的 softmax。$N = 1$ 时，M 个查询直接读取唯一一组的 Z 个描述，不需要特殊的跨组退化处理。

5 生成主干与 flow 起点

5.1 目标 patch 与主干结构

采用带风格交叉注意力的 DiT 主干。在每个时刻，将当前图像与干净目标标准字沿通道拼接：

$$T^{(0)} = \mathrm{PatchEmbed}_{\mathrm{gen}}([x_t, K_\star]) + P_{xy} \in \mathbb{R}^{L\times d}.$$

主干始终保留 $L = (n/p)^2$ 个空间 token；参考分支与目标分支的分块投影不共享参数。每个 block 依次执行目标自注意力 SA、读取 S 的交叉注意力 CA，以及逐 token FFN。此处 SA、CA 表示独立的注意力子层，FFN 单独列出；不重复套用参考分支中包含 FFN 的复合块定义。

时间调节只施加于 SA、FFN，以及输出头。 SA 与 FFN 沿用原始 DiT 的 AdaLN-Zero 配置；新增 CA 采用普通前置 LN 与残差，不另外生成时间缩放、偏移或门控。不同 block 各自将同一个 S 投影成键和值。CA 的查询来自已经受时间影响的主干特征，因此仍然能够随 t 改变读取方式。

5.2 时间输入：标准 AdaLN-Zero 与普通 CA

连续时间 $t \in [0,1]$ 经正弦余弦编码及两层线性映射（中间使用 SiLU）得到共享的 $e(t) \in \mathbb{R}^d$。编码的时间尺度在训练与推理时保持一致；t 表示流的位置，不是积分步号或步长。每个 block 使用自己的一次映射：

$$(a_s, b_s, g_s, a_f, b_f, g_f) = \mathrm{Split}_6\left(W^{(b)}_{\mathrm{mod}}\,\mathrm{SiLU}(e(t)) + c^{(b)}_{\mathrm{mod}}\right), \qquad W^{(b)}_{\mathrm{mod}} : \mathbb{R}^d \to \mathbb{R}^{6d}.$$

下标 s, f 分别表示 SA 与 FFN。六个向量均为 d 维，在该样本的全部 L 个 token 间广播；不同 block 使用不同参数，同一 block 内通过一个线性层一次性生成六组输出。定义

$$D_j(T,t) = (1 + a_j(t)) \odot \mathrm{LN}_j(T) + b_j(t), \qquad j \in \{s, f\}.$$

受时间调节的 LN 不再带自身的可学习仿射参数。一个 block 的完整更新为

$$\begin{aligned}
A &= D_s(T,t),\\
T_s &= T + g_s(t) \odot \mathrm{MHA}_s(A, A, A),\\
T_c &= T_s + \mathrm{MHA}_c(\mathrm{LN}_q(T_s), \mathrm{LN}_{kv}(S), \mathrm{LN}_{kv}(S)),\\
T^+ &= T_c + g_f(t) \odot \mathrm{FFN}(D_f(T_c,t)).
\end{aligned}$$

CA 中的 Q、K、V 投影仍然彼此独立；注意力矩阵为 $L \times M$。主干不直接读取 R_i 或 U_i，参考表示 S 本身不接受时间调节。

$W_{\mathrm{mod}}^{(b)}$ 及其偏置零初始化，因此 SA、FFN 的缩放增量、偏移与残差门初始均为零；门控向量通过训练学习，不使用额外 sigmoid。新增 CA 保留普通残差，不引入额外零门，所以此扩展 block 整体不保证初始恒等；AdaLN-Zero 的零残差初始化作用于 SA、FFN 两个分支。

输出头另用 $\mathrm{SiLU} + \mathrm{Linear}(d, 2d)$ 生成 $(a_{\mathrm{out}}, b_{\mathrm{out}})$，对最终 $L \times d$ 特征做时间调节的归一化，再用所有 token 共用的线性层 $d \to p^2$：

$$L \times d \xrightarrow{\text{时间调节 LN + 共享线性层}} L \times p^2 \xrightarrow{\text{按原二维位置拼回}} \widehat{v}_t \in \mathbb{R}^{n \times n \times 1}.$$

沿用原始 DiT 的输出头初始化，时间调节映射与最终 patch 线性映射均零初始化。输出矩阵只有 $d \times p^2$ 个权重，不随 L 增长；不存在把整图压成一个 token 后再解码的步骤。输出是当前灰度状态的像素速度，而不是最终字图；$K_\star$ 是额外输入条件，不占用输出通道。

5.3 训练路径：标准字加噪声到手写真值

本稿暂在像素空间定义 flow，不额外引入图像自编码器。主干内部的 patch 特征不是独立的生成状态；若将来改为 latent flow，需另行定义共同编码空间与解码器。

取固定实验超参数 $\sigma > 0$，独立采样 $\epsilon \sim \mathcal{N}(0, I)$ 和 $t \sim \mathcal{U}(0, 1)$，定义

$$\begin{aligned} x_0 &= K_\star + \sigma\epsilon, \\ x_t &= (1-t)x_0 + tH_\star, \\ u &= H_\star - x_0, \\ \mathcal{L} &= \mathbb{E}\left[\frac{1}{n^2}\left\|v_\theta(x_t, t, K_\star, S) - u\right\|_F^2\right]. \end{aligned}$$

同一个 x_0 同时用于构造 x_t 和监督速度 u。干净标准字 $K_\star$ 始终作为条件提供；$H_\star$ 仅通过训练状态与监督目标参与训练。参考分支的所有可学习查询、编码器和生成主干均由该损失联合训练。本稿尚未引入额外的笔画标注损失、风格解耦损失或重建损失。

这里的加噪是以标准字为均值的加性高斯扰动，不是把图像与噪声做权重和为 1 的混合。x_0 可能超出 $[-1, 1]$；训练状态和积分中间状态均不裁剪。训练和推理必须使用相同的起点分布；不能仅在推理时替换纯噪声起点。

5.4 推理与随机性

先计算 S，再采样 $x_0 = K_\star + \sigma\epsilon$，固定 $S, K_\star$ 并求解

$$\frac{dx_t}{dt} = v_\theta(x_t, t, K_\star, S), \qquad t : 0 \longrightarrow 1.$$

暂采用 J 步等步长 Euler 积分：

$$t_j = j/J, \qquad x_{t_{j+1}} = x_{t_j} + \frac{1}{J} v_\theta(x_{t_j}, t_j, K_\star, S).$$

仅在最后把 x_1 裁剪至 $[-1, 1]$ 并映射回灰度范围，得到 $\widehat{H}_\star$。除初始噪声外，生成过程不引入额外随机量。

当参考、目标和噪声固定时，输出确定。$\sigma = 0$ 可另作确定性迁移对照，但同一条件下的确定性 ODE 无法产生多个不同写法。更大 σ 不自动意味着更多合理变化；若需要推理时可调的噪声强度，应另行设计覆盖不同强度的训练和相应条件输入，本稿没有默认支持这一能力。

6 计算成本与压缩的实际含义

以下仅统计注意力中计算权重与加权求和的主要项，并将重复层数显式写出；忽略常数。投影和前馈网络的成本通常还包含“token 数量乘 d^2”的项。

操作	主要注意力成本
N 组分别进行 L 个 patch 的自注意力	$O(NL^2d)$
每组用 Z 个查询读取 L 个特征	$O(NZLd)$
B_{set} 个集合汇总层：CA 读取 NZ 个描述并对 M 个 token 做 SA	$O\big(B_{\text{set}}(MNZ + M^2)d\big)$
一个主干层的目标自注意力	$O(L^2d)$
一个主干层读取风格条件	$O(LMd)$

计入参考分支的实际层数，本稿默认结构的主要注意力成本为

$$O\big(B_{\text{local}}NL^2d + NZLd + B_{\text{set}}(MNZ + M^2)d\big)\,.$$

参考描述不做全局自注意力，故不包含 $O(N^2Z^2d)$ 或 $O((Nq^2)^2d)$ 的计算项；新增自注意力只发生在固定数量的 M 个风格 token 上。固定 $L, Z, M, d, B_{\text{local}}, B_{\text{set}}$ 时，参考分支的上述计算成本仍随 N 线性增长。若不做逐组压缩，而让每层的 M 个查询直接读取全部 NL 个组内特征，集合 CA 成本为 $O(B_{\text{set}}MNLd)$。压缩后单层及全部层的 CA 读取项之比均为 Z/L；例如 $L = 256, Z = 16$ 时，该项变为 $1/16$。这一比较不包含新增的逐组压缩成本，不能据此宣称整个参考分支加速 16 倍。

参考编码不在 flow 积分循环内重复执行；相同参考可复用其输出。若主干有 B_{gen} 层、采样有 J 步，其注意力成本约为 $O(JB_{\text{gen}}(L^2 + LM)d)$。实际训练显存和时间还取决于批量大小、反向传播、前馈宽度与注意力实现。FlashAttention 可降低中间矩阵的显存开销；本版关于 N 的线性计算规模来自结构本身。

压缩的代价同样明确：某种少见笔画或部件证据若在生成 U_i 时已经丢失，后续 M 个查询只能利用保留下来的信息，不能通过重新读取 R_i 找回它。因此 Z 控制单字证据容量，M 控制集合汇总宽度，B_{set} 控制反复读取和风格 token 交互的深度，三者应分别考察。