Glyph2Hand

分层参考编码与条件流匹配：文字审阅稿

2026 年 10 月 4 日　本版仅含文字、公式和形状表，确认后再绘图

1　任务、范围与核心假设

根据同一书写者的若干参考字，生成指定汉字的手写图。输入为

$$\mathcal{C} = \{(H_i, K_i)\}_{i=1}^{N}, \qquad K_\star,$$

其中 H_i 是参考手写图，K_i 是同一个汉字的标准楷体图；$K_\star$ 是目标汉字的楷体图。一组指一个对应的 (H_i, K_i)，不是一张独立图像。所有参考手写图来自同一书写者，$N \geq 1$。输出 $\widehat{H}_\star$ 应同时保持目标字内容和参考笔迹风格。训练真值 $H_\star$ 不进入参考集合，也不作为生成网络的独立条件输入。

本版参考分支采用以下顺序：

1. 每组独立编码，在整字上下文中理解局部形状以及手写与楷体之间的关系。
2. 每组压缩为 Z 个语义描述 token，表示从该参考字中观察到的写法证据。
3. 由 M 个可学习查询直接读取拼接后的全部 NZ 个描述，通过交叉注意力得到风格 token，供生成主干读取。

核心假设：组内结构已被编码进 Z 个描述，后续融合可以主要依据描述内容，不再显式依赖原始 patch 的分组关系。这不意味着字符内容被完全消除，也不保证每个 token 对应一种笔画。笔画、部件及其位置仍可能是解释某种写法所必需的信息。这一假设和压缩容量需要通过实验验证；当前文档是待审阅设计，尚无实现或效果结论。

生成分支暂按“目标楷体加噪声作为起点”的像素空间 flow 写出完整公式。噪声强度、各层数和 token 数量尚未确定，末节列出需要审阅的选择。

2　统一符号与数据形状

所有图像先映射至 $[-1, 1]$，采用 $n \times n$ 单通道灰度图。块边长为 p，要求 $p \mid n$。每边块数为 $q = n/p$，每组块数为 $L = q^2$。这里使用 q 表示每边块数，避免与 flow 状态 x_t 混淆。下表省略批次维；每行特征都是一个 d 维 token。

符号	形状 / 含义	职责
N	参考对数量	随输入变化，至少为 1
Z	每组描述数量	单字证据容量，固定超参数
M	最终风格数量	整个参考集合的输出容量，固定超参数
X_i	$L \times d$	第 i 组的初始 patch 特征
R_i	$L \times d$	经过组内注意力的空间特征
Q_Z	$Z \times d$	所有组共用的可学习压缩查询
U_i	$Z \times d$	第 i 组的语义描述
U	$NZ \times d$	全部组描述沿行拼接，直接提供键和值
Q_M	$M \times d$	可学习的集合汇总查询
S	$M \times d$	最终风格条件
$T^{(b)}$	$L \times d$	生成主干第 b 层的目标特征
$x_t, \widehat{v}_t$	$n \times n \times 1$	当前生成状态、预测像素速度

Z 和 M 都表示 token 数量，不表示特征维度；它们不必相等，也没有预设大小关系。Q_Z, Q_M 是训练得到的模型参数，不是每次生成时重新采样的随机量。

3 参考分支：从成对字图到固定风格表示

3.1 注意力块的具体约定

为使下文公式没有歧义，本文采用带残差、前置层归一化和前馈网络的注意力块。交叉注意力块 $\mathrm{CA}(A,B)$ 由 A 提供查询，B 提供键和值：

$$\begin{aligned}\widetilde{A} &= A + \mathrm{MHA}(\mathrm{LN}_A(A), \mathrm{LN}_B(B), \mathrm{LN}_B(B)),\\ \mathrm{CA}(A,B) &= \widetilde{A} + \mathrm{FFN}(\mathrm{LN}_F(\widetilde{A})).\end{aligned}$$

自注意力块 $\mathrm{SA}(A)$ 为

$$\begin{aligned}\widetilde{A} &= A + \mathrm{MHA}(\mathrm{LN}_A(A), \mathrm{LN}_A(A), \mathrm{LN}_A(A)),\\ \mathrm{SA}(A) &= \widetilde{A} + \mathrm{FFN}(\mathrm{LN}_F(\widetilde{A})).\end{aligned}$$

这里的 LN 是逐 token 的层归一化，不是 QKV 投影。$\mathrm{MHA}(X_Q, X_K, X_V)$ 的三个参数表示投影前的特征来源，模块内部再进行各头的 QKV 线性投影。以第 h 个头为例，省略可选偏置：

$$\begin{aligned}Q_h &= X_Q W_Q^{(h)}, \qquad K_h = X_K W_K^{(h)}, \qquad V_h = X_V W_V^{(h)},\\ O_h &= \mathrm{softmax}\!\left(\frac{Q_h K_h^\top}{\sqrt{d_h}}\right) V_h,\\ \mathrm{MHA}(X_Q, X_K, X_V) &= \mathrm{Concat}_h(O_h) W_O.\end{aligned}$$

d_h 是每头维度，W_O 是多头结果拼接后的输出投影。本稿的 $W_Q^{(h)}, W_K^{(h)}, W_V^{(h)}$ 分别参数化，不共享权重。因此自注意力中三个输入均为 $\mathrm{LN}_A(A)$，仅表示 Q、K、V 来自同一份特征，不施加投影后的 $Q_h = K_h = V_h$ 约束。同理，交叉注意力中键和值均来自 $\mathrm{LN}_B(B)$，也不表示 $K_h = V_h$。

与共享键值的区别：在本稿所用的相同键值维度下，若将 K、V 投影及其偏置（如有）绑定，或直接令 $V_h = K_h$，才是显式约束投影后 $K = V$ 的另一种结构；本稿不采用该约束。上述 QKV 投影约定也适用于生成主干中的多头注意力。前馈网络暂用两层线性映射和 GELU；归一化仅沿特征维，不跨 token 或参考组。不同阶段、不同层拥有各自参数；只有明确说明的逐组操作共享参数。

下文“注意力池化”采用 Set Transformer 的 PMA 思想：固定数量的可学习查询读取可变数量的输入。这里给出了本稿使用的具体块结构，不宣称逐项复现原论文的归一化和前馈配置。

3.2 阶段 A：组内分块与上下文编码

将一组 H_i, K_i 沿通道拼接为 $n \times n \times 2$。同位置的两个 $p \times p$ 小块一起展开，得到 $2p^2$ 维向量，再投影到 d 维。这不是把手写和楷体混合平均，也不是分别产生两套无配对关系的 token。定义

$$X_i = \mathrm{PatchEmbed}_{\mathrm{ref}}([H_i, K_i]) + P_{xy} \in \mathbb{R}^{L \times d}, \qquad R_i = E_{\mathrm{local}}(X_i).$$

$P_{xy} \in \mathbb{R}^{L \times d}$ 为图内二维位置编码；暂用固定二维正弦余弦编码。E_{local} 由 B_{local} 层 SA 组成。每组的 L 个 token 可以互相读取，但此阶段不读取其他参考组。所有组使用相同的分块投影、位置编码和编码器参数。

这一阶段保留 L 个空间位置。目的在于先获得带整字上下文的局部描述，为跨字比较提供依据；仅添加二维位置、然后直接把原始 patch 混合，不能完整表达哪些 patch 属于同一个字。组内编码也不保证自动学到可解释的笔画分类。

3.3 阶段 B：每组压缩为 Z 个语义描述

用同一套可学习查询 $Q_Z \in \mathbb{R}^{Z \times d}$ 独立读取各组：

$$U_i = \mathrm{CA}_{\text{local pool}}(Q_Z, R_i) \in \mathbb{R}^{Z \times d}.$$

查询来自 Q_Z，键和值来自第 i 组的 R_i。每个查询均可读取该组的全部 L 个空间特征；输出位置对应查询槽位，不再对应固定图像块。各组之间共享 Q_Z 和此注意力块的全部参数。

本稿的最简版本采用一次上述压缩，随后拼接各组描述，直接供 M 个查询读取。压缩后的 U_i 不再进行组内或跨组自注意力。压缩后不再保留 R_i 到主干或最终池化的旁路，因而 Z 是真实的信息瓶颈。

相同查询槽位为跨字描述提供共同的学习起点，但不强制语义完全对齐。例如不能预先断言“第一个 token 永远表示横画”。这里的 U_i 是来自单字的证据：有些写法在该字中没有出现，模型需要在后续集合融合中结合其他字。压缩不会自动实现内容与风格的严格解耦，也不要求每个描述能独立解释。

3.4 阶段 C：交叉注意力汇总为 M 个风格 token

将各组描述沿 token 维拼接，直接作为交叉注意力的键值来源。另设 M 个可学习查询 $Q_M \in \mathbb{R}^{M\times d}$，完成集合汇总：

$$U = [U_1; \ldots; U_N] \in \mathbb{R}^{NZ\times d},$$
$$S = \mathrm{CA}_{\text{set pool}}(Q_M, U) \in \mathbb{R}^{M\times d}.$$

拼接只是此汇总块的输入整理，不含可学习参数，也不构成独立的编码阶段。**这 NZ 个描述不进行自注意力；各组信息直接汇入 M 个输出 token**。查询来自 Q_M，键和值来自 U；每个查询都能读取全部有效的 NZ 个描述。单头的注意力权重矩阵形状为 $M \times NZ$，不是 $NZ \times NZ$。该块仅更新 M 个查询侧 token，不向 U 写回信息。这里的“不更新 U”指前向计算中的信息流；训练梯度仍可通过键值分支回传至逐组编码器。Q_M 与 Q_Z 是不同的参数集合，即使 $M = Z$ 也不共享。本稿默认一次最终汇总，不额外增加输出 token 的自注意力层。

汇总时不添加参考组序号、拼接后的绝对序列位置或新的空间网格位置。组内空间与上下文信息可以存在于描述内容中，但查询不再显式访问原始分组关系。这沿用阶段 B 的假设：压缩描述应足以支持内容驱动的集合汇总。

S 表示对整个参考集合的风格总结；其行数与 N 无关，但数值内容依赖全部有效参考。M 是表示容量，不等于预先定义的中文风格属性数量。参考分支只依赖 $\mathcal{C}$，不依赖目标字 $K_\star$、时间 t 或当前状态 x_t。因此同一组参考的 S 可以在多个目标字和各 flow 步之间复用。训练时不截断其梯度，参考分支与生成主干联合优化；训练更新后缓存需重新计算。

4 参考顺序无关性与可变数量输入

本任务要求参考对整体重排不改变输出；不允许仅重排 H_i 或仅重排 K_i。逐组编码与压缩使用共享参数，因此组重排只会重排 U 的整组行，得到 $U' = PU$。由于键值投影与归一化均逐 token 进行，对应有 $K' = PK$、$V' = PV$。固定的 M 个查询对键和值的同步重排不变。以单头为例，

$$\mathrm{softmax}\left(\frac{Q(PK)^\top}{\sqrt{d_h}}\right)PV = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_h}}\right)V.$$

逐 token 的归一化、前馈网络以及查询侧残差不破坏该性质，所以最终 S 不变。固定初始噪声和积分设置后，生成结果也不变，允许浮点计算误差。本稿暂不使用 dropout；若以后引入随机操作，需区分确定性推理与随机训练中的性质。

批处理中不同样本可以有不同 N。补齐参考组产生的全部 Z 个描述必须在最终交叉注意力中作为无效键值屏蔽。M 个查询均有效，但不得读取这些补齐 token。应避免给一个查询构造全部键均不可见的 softmax。$N = 1$ 时，M 个查询直接读取唯一一组的 Z 个描述，不需要特殊的跨组退化处理。

5 生成主干与 flow 起点

5.1 目标 patch 如何读取风格

沿用交叉注意力 DiT 的生成主干，但参考键值长度改为固定 M。在每个时刻，将当前图像与干净目标楷体沿通道拼接：

$$T^{(0)} = \mathrm{PatchEmbed}_{\text{gen}}([x_t, K_\star]) + P_{xy} \in \mathbb{R}^{L\times d}.$$

参考分支与目标分支的分块投影不要求共享参数。每个 DiT 层依次执行目标内部自注意力、读取 S 的交叉注意力，以及逐 token 前馈网络。各子层使用时间调节、门控和残差；不同层各自把同一个 S 投影成键

和值。

交叉注意力的单头形式为

$$Q = \mathrm{AdaLN}(T,t)W_Q, \qquad K = \mathrm{LN}(S)W_K, \qquad V = \mathrm{LN}(S)W_V,$$
$$O = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_h}}\right)V.$$

其中 Q 的形状为 $L \times d_h$，K, V 为 $M \times d_h$，注意力权重为 $L \times M$。主干可以读取所有风格 token；它不直接读取 R_i 或 U_i。

时间 t 经正弦余弦编码与两层 SiLU 前馈映射得到 $e(t)$。沿用 AdaLN-Zero：每个子层各产生一组 $a(t), b(t), g(t) \in \mathbb{R}^d$，在目标 token 间共享，

$$\mathrm{AdaLN}(T,t) = (1 + a(t)) \odot \mathrm{LN}(T) + b(t).$$

子层结果乘 $g(t)$ 后加回输入；产生各组调节与门控向量的最后线性层零初始化。输出头使用时间调节的归一化和 $d \to p^2$ 线性映射，再将 L 个速度块按原二维位置拼回 $\widehat{v}_t \in \mathbb{R}^{n \times n \times 1}$。输出是像素速度，不是最终字图。

5.2 训练路径：楷体加噪声到手写真值

本稿暂在像素空间定义 flow，不额外引入图像自编码器。主干内部的 patch 特征不是独立的生成状态；若将来改为 latent flow，需另行定义共同编码空间与解码器。

取固定实验超参数 $\sigma > 0$，独立采样 $\epsilon \sim \mathcal{N}(0, I)$ 和 $t \sim \mathcal{U}(0,1)$，定义

$$\begin{aligned} x_0 &= K_\star + \sigma\epsilon, \\ x_t &= (1-t)x_0 + tH_\star, \\ u &= H_\star - x_0, \\ \mathcal{L} &= \mathbb{E}\left[\frac{1}{n^2}\left\|v_\theta(x_t, t, K_\star, S) - u\right\|_F^2\right]. \end{aligned}$$

同一个 x_0 同时用于构造 x_t 和监督速度 u。干净楷体 $K_\star$ 始终作为条件提供；$H_\star$ 仅通过训练状态与监督目标参与训练。参考分支的所有可学习查询、编码器和生成主干均由该损失联合训练。本稿尚未引入额外的笔画标注损失、风格解耦损失或重建损失。

这里的加噪是以楷体为均值的加性高斯扰动，不是把图像与噪声做权重和为 1 的混合。x_0 可能超出 $[-1,1]$；训练状态和积分中间状态均不裁剪。训练和推理必须使用相同的起点分布；不能仅在推理时替换纯噪声起点。

5.3 推理与随机性

先计算 S，再采样 $x_0 = K_\star + \sigma\epsilon$，固定 $S, K_\star$ 并求解

$$\frac{dx_t}{dt} = v_\theta(x_t, t, K_\star, S), \qquad t : 0 \longrightarrow 1.$$

暂采用 J 步等步长 Euler 积分：

$$t_j = j/J, \qquad x_{t_{j+1}} = x_{t_j} + \frac{1}{J}v_\theta(x_{t_j}, t_j, K_\star, S).$$

仅在最后把 x_1 裁剪至 $[-1,1]$ 并映射回灰度范围，得到 $\widehat{H}_\star$。除初始噪声外，生成过程不引入额外随机量。

当参考、目标和噪声固定时，输出确定。$\sigma = 0$ 可另作确定性迁移对照，但同一条件下的确定性 ODE 无法产生多个不同写法。更大 σ 不自动意味着更多合理变化；若需要推理时可调的噪声强度，应另行设计覆盖不同强度的训练和相应条件输入，本稿没有默认支持这一能力。

6 计算成本与压缩的实际含义

以下仅统计注意力中计算权重与加权求和的主要项；忽略常数，并先假设各阶段各执行一次。投影和前馈网络的成本通常还包含“token 数量乘 d^2”的项。

操作	主要注意力成本
N 组分别进行 L 个 patch 的自注意力	$O(NL^2d)$
每组用 Z 个查询读取 L 个特征	$O(NZLd)$
M 个查询直接读取全部 NZ 个描述	$O(MNZd)$
一个主干层的目标自注意力	$O(L^2d)$
一个主干层读取风格条件	$O(LMd)$

计入参考分支的实际层数，本稿默认结构的主要注意力成本为

$$O\big(B_{\text{local}}NL^2d + NZLd + MNZd\big)\,.$$

本稿不存在全部参考 token 的全局自注意力，因此没有 $O(N^2Z^2d)$ 或 $O((Nq^2)^2d)$ 的计算项。固定 L, Z, M, d 和组内层数时，参考分支的上述计算成本随 N 线性增长。若不做逐组压缩，而让 M 个查询直接读取全部 NL 个组内特征，最终读取成本为 $O(MNLd)$。压缩后该读取项之比为 Z/L；例如 $L = 256, Z = 16$ 时，该项变为 1/16。这一比较不包含新增的逐组压缩成本，不能据此宣称整个参考分支加速 16 倍。

参考编码不在 flow 积分循环内重复执行；相同参考可复用其输出。若主干有 B_{gen} 层、采样有 J 步，其注意力成本约为 $O(JB_{\text{gen}}(L^2 + LM)d)$。实际训练显存和时间还取决于批量大小、反向传播、前馈宽度与注意力实现。FlashAttention 可降低中间矩阵的显存开销；本版关于 N 的线性计算规模来自结构本身。

压缩的代价同样明确：某种少见笔画或部件证据若在生成 U_i 时已经丢失，后续 M 个查询只能利用保留下来的信息，不能通过重新读取 R_i 找回它。因此 Z 控制单字证据容量，M 控制集合汇总容量，两者应分别考察。

7 本版选择与待审阅项目

本稿已明确采用的结构：共享成对 patch 编码；组内自注意力；每组一次 Z 查询压缩；拼接 NZ 个描述后，直接由 M 个查询做一次交叉注意力汇总；主干仅通过 S 读取参考。参考描述不进行全局自注意力，不使用参考组序号，也不保留未压缩参考特征的旁路。

为了写出可实现公式而暂定的细节：参考块使用前置归一化和 GELU 前馈网络；两处池化均采用一个交叉注意力块；不增加压缩后组内自注意力或最终风格自注意力；不使用 dropout。这些是审阅稿的具体约定，不是已经验证的最优配置。

尚待确定的参数： n, p, d, Z, M、组内层数、主干层数、注意力头数、前馈宽度、噪声强度 σ 和积分步数 J。参考数量 N 的训练采样范围及推理上限也尚未确定。

优先验证的问题：在固定其他结构时调整 Z，检查少见笔画与部件写法是否因组内压缩丢失；再调整 M 评估最终汇总容量，并检查参考字数量及笔画覆盖变化时的生成表现。flow 起点可分别训练纯噪声、纯楷体和楷体加噪声对照，比较字形正确性、风格一致性、合理变化与采样成本。

未来可扩展为 RGB，或研究粗细、直曲及更大幅度的风格变化；颜色通道的扩展本身不保证这些能力。当前优先审阅并验证上述灰度模型。

8 方法依据

- Set Transformer（ICML 2019）：提供可学习查询池化 PMA 的依据。本文的“逐字上下文编码后压缩，再直接用 M 个查询进行集合汇总”是针对当前任务的组合，不是该论文对中文风格表示的验证结论。作者的公开 PyTorch 实现 可用于核对注意力块和可学习查询池化的基本结构。
- Rectified Flow（2022）与 Flow Matching for Generative Modeling（2022）：为通过速度回归学习连续生成路径提供方法依据。本稿使用成对楷体、手写真值和带噪起点定义条件路径，不预设它优于纯噪声路径。
- SDEdit与 I^{2}SB：分别提供源图加噪编辑和图像间随机桥的参考；本稿的线性插值 ODE 训练不等同于这两种算法。